S.I.K.O.R.K.A.

System **I**nteligentnej **K**ompilacji **O**pinii, **R**aportów, **K**onfiguracji i **A**naliz

Specyfikacja Techniczna

Wersja	1.0
Data	Grudzień 2025
Zespół	Wifi nie działa
Hackathon	Hacknation/Scenariusze Jutra

„Mała, ale inteligentna – jak sikorka, która szybko przetwarza informacje z otoczenia"

Spis Treści

1. Wprowadzenie

1.1 Nazwa Projektu

S.I.K.O.R.K.A. – **S**ystem **I**nteligentnej **K**ompilacji **O**pinii, **R**aportów, **K**onfiguracji i **A**naliz

Nazwa projektu nawiązuje do ptaka sikorki – małego, ale niezwykle inteligentnego i adaptacyjnego stworzenia, które potrafi szybko przetwarzać informacje z otoczenia i dostosowywać swoje zachowanie. Podobnie nasz system szybko przetwarza różnorodne źródła danych i adaptuje się do potrzeb analityka.

1.2 Cel Projektu

System **S.I.K.O.R.K.A.** to narzędzie analityczne wykorzystujące modele LLM (Large Language Models) do automatycznej ekstrakcji faktów, generowania predykcji i tworzenia raportów analitycznych dla fikcyjnego państwa **Atlantis**. System wspiera proces podejmowania decyzji strategicznych poprzez:

- Automatyczną ekstrakcję kluczowych faktów z różnorodnych źródeł
- Identyfikację potencjalnych scenariuszy (pozytywnych i negatywnych)
- Wykrywanie brakujących informacji (unknowns)
- Generowanie kompleksowych raportów z rekomendacjami

1.3 Potencjał Wdrożeniowy

Aspekt	Opis
Konteneryzacja	Pełna konteneryzacja Docker – system działa na dowolnej infrastrukturze wspierającej Docker

Aspekt	Opis
Modele Open Source	Wykorzystanie wyłącznie modeli open-source (Llama 3.1, Qwen3) – brak vendor lock-in
Elastyczność LLM	Prosty mechanizm podmiany providera LLM (zmienna `LLM_PROVIDER`)
Koszty	Podczas intensywnych testów zużyto ~10k neuronów Cloudflare (~$0.11)
Self-hosting	Możliwość hostowania własnego LLM (Ollama) z określonym, skalowalnym kosztem
Skalowalność	Architektura mikroserwisowa umożliwia niezależne skalowanie komponentów

---

2. Architektura Systemu

2.1 Diagram C4 – Poziom Kontekstu

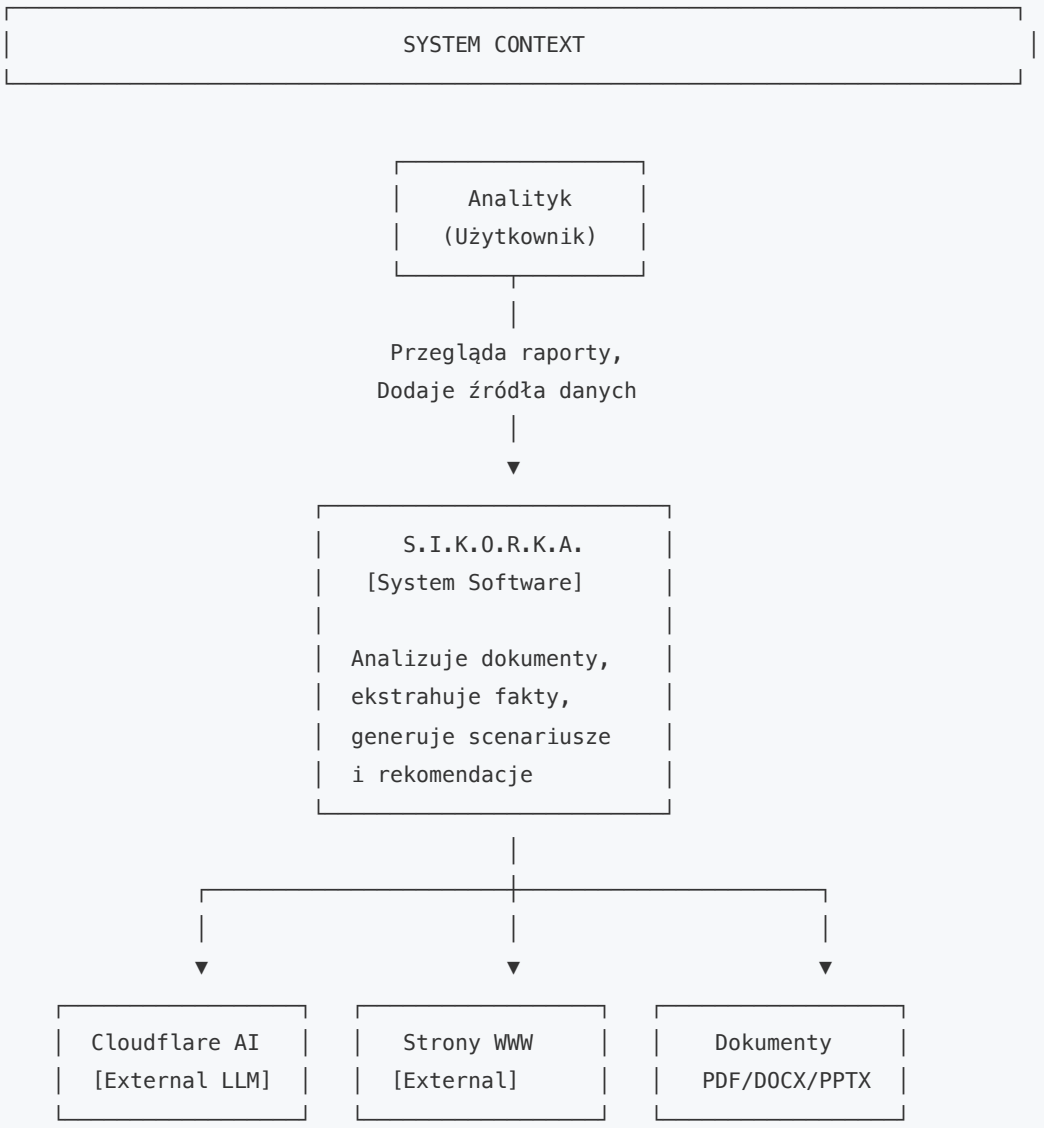

2.2 Diagram C4 – Poziom Kontenerów

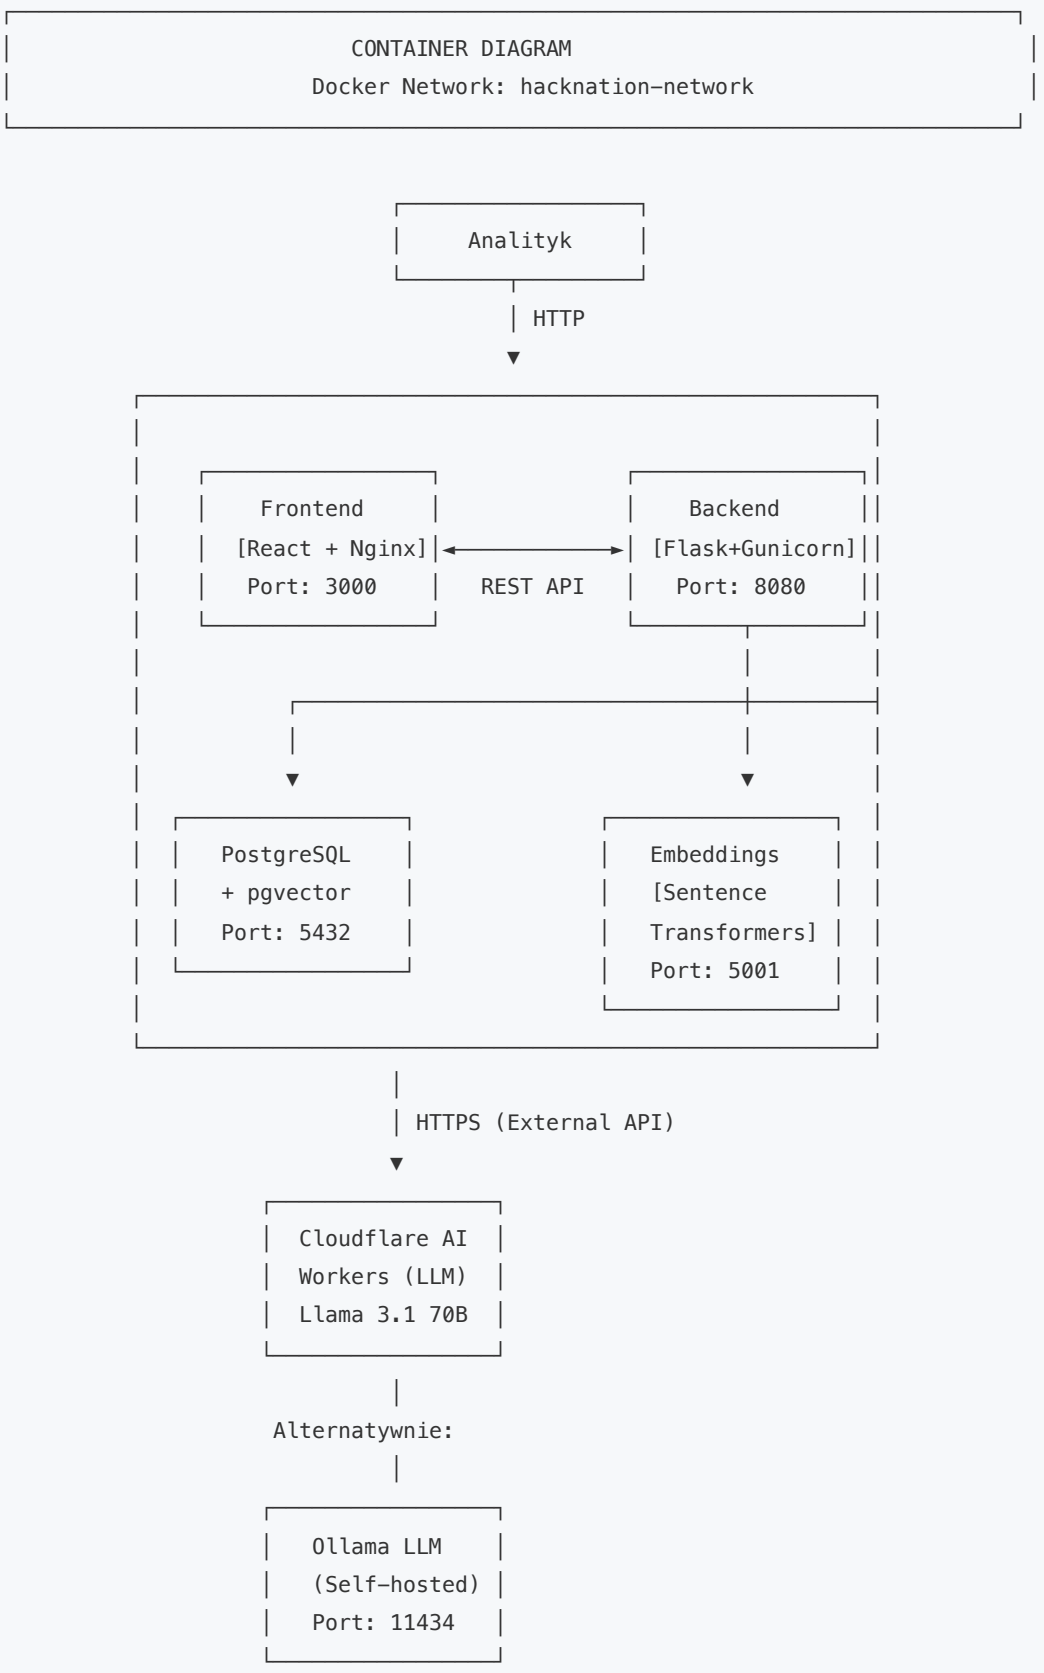
CONTAINER DIAGRAM
Docker Network: hacknation-network
Analityk
HTTP
Frontend
[React + Nginx]
Port: 3000
REST API
Backend
[Flask+Gunicorn]
Port: 8080
PostgreSQL
+ pgvector
Port: 5432
Embeddings
[Sentence
Transformers]
Port: 5001
HTTPS (External API)
Cloudflare AI
Workers (LLM)
Llama 3.1 70B
Alternatywnie:
Ollama LLM
(Self-hosted)
Port: 11434

2.3 Diagram C4 – Poziom Komponentów (Backend)

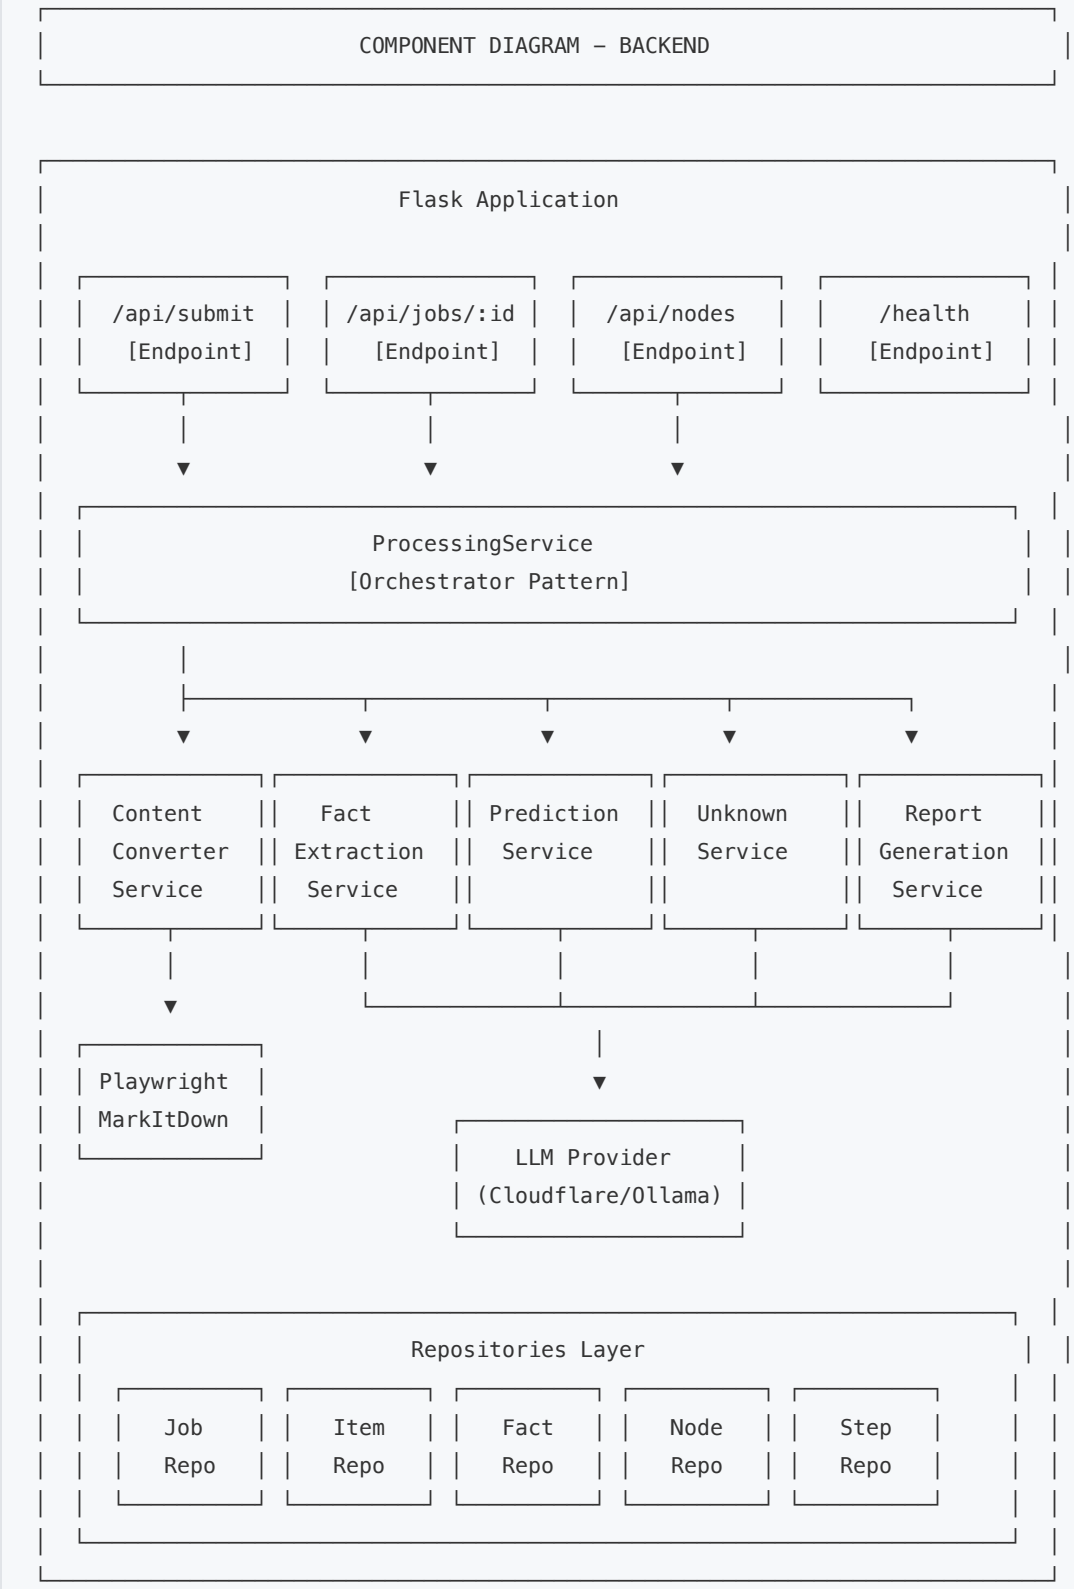

3. Diagram Sekwencji – Submit Job Flow

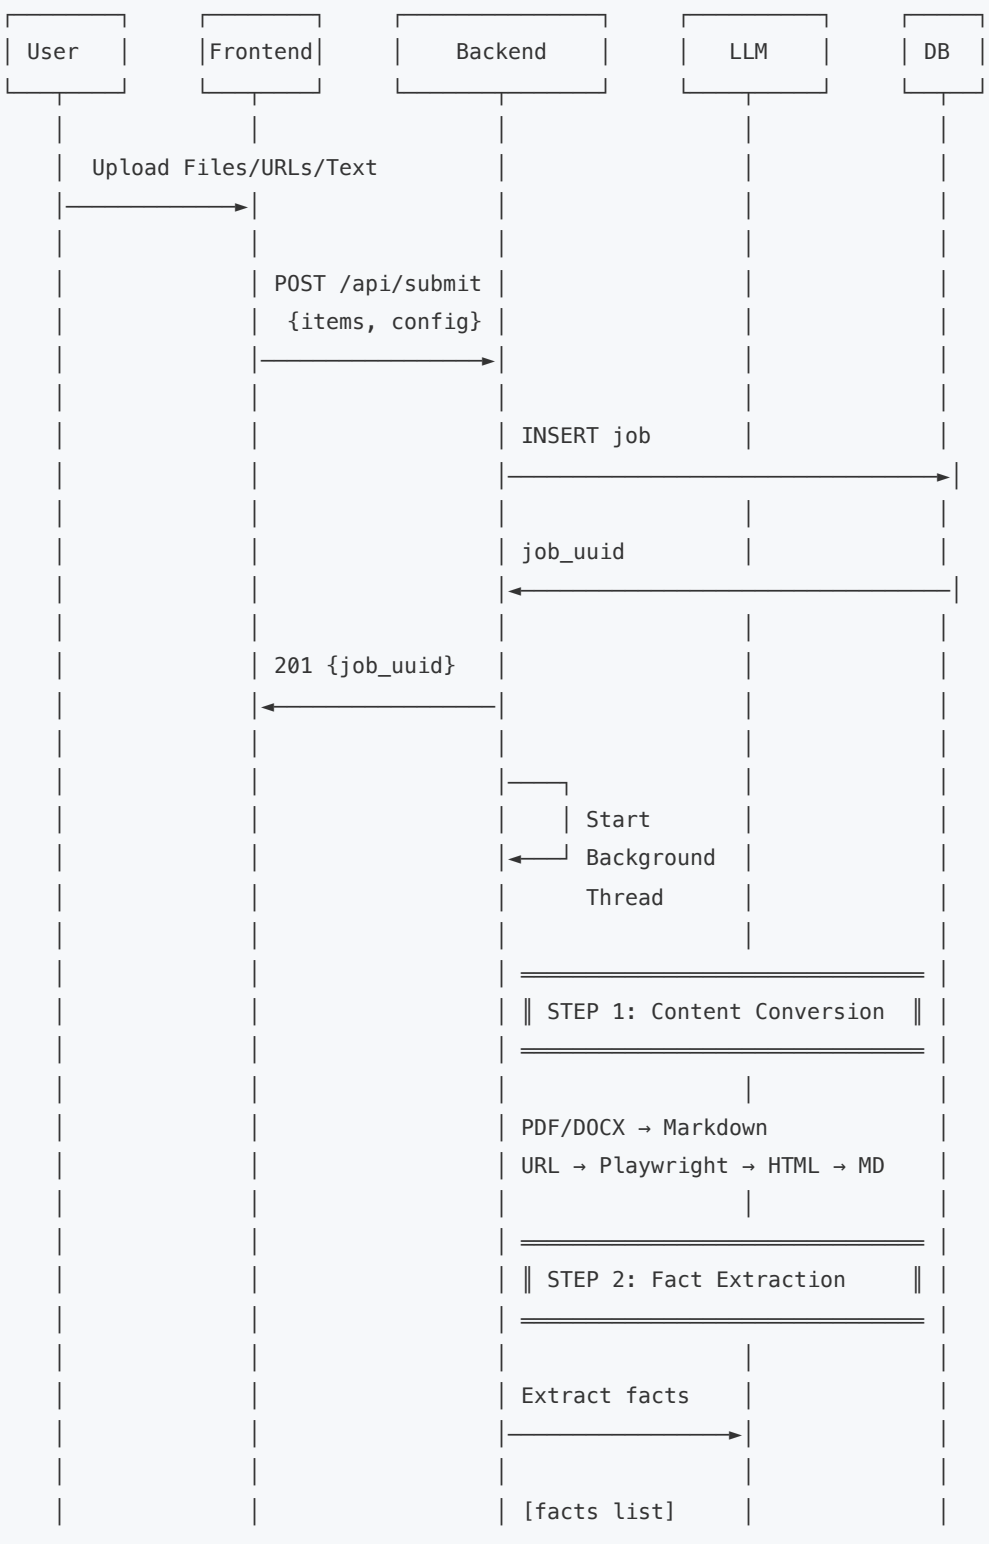

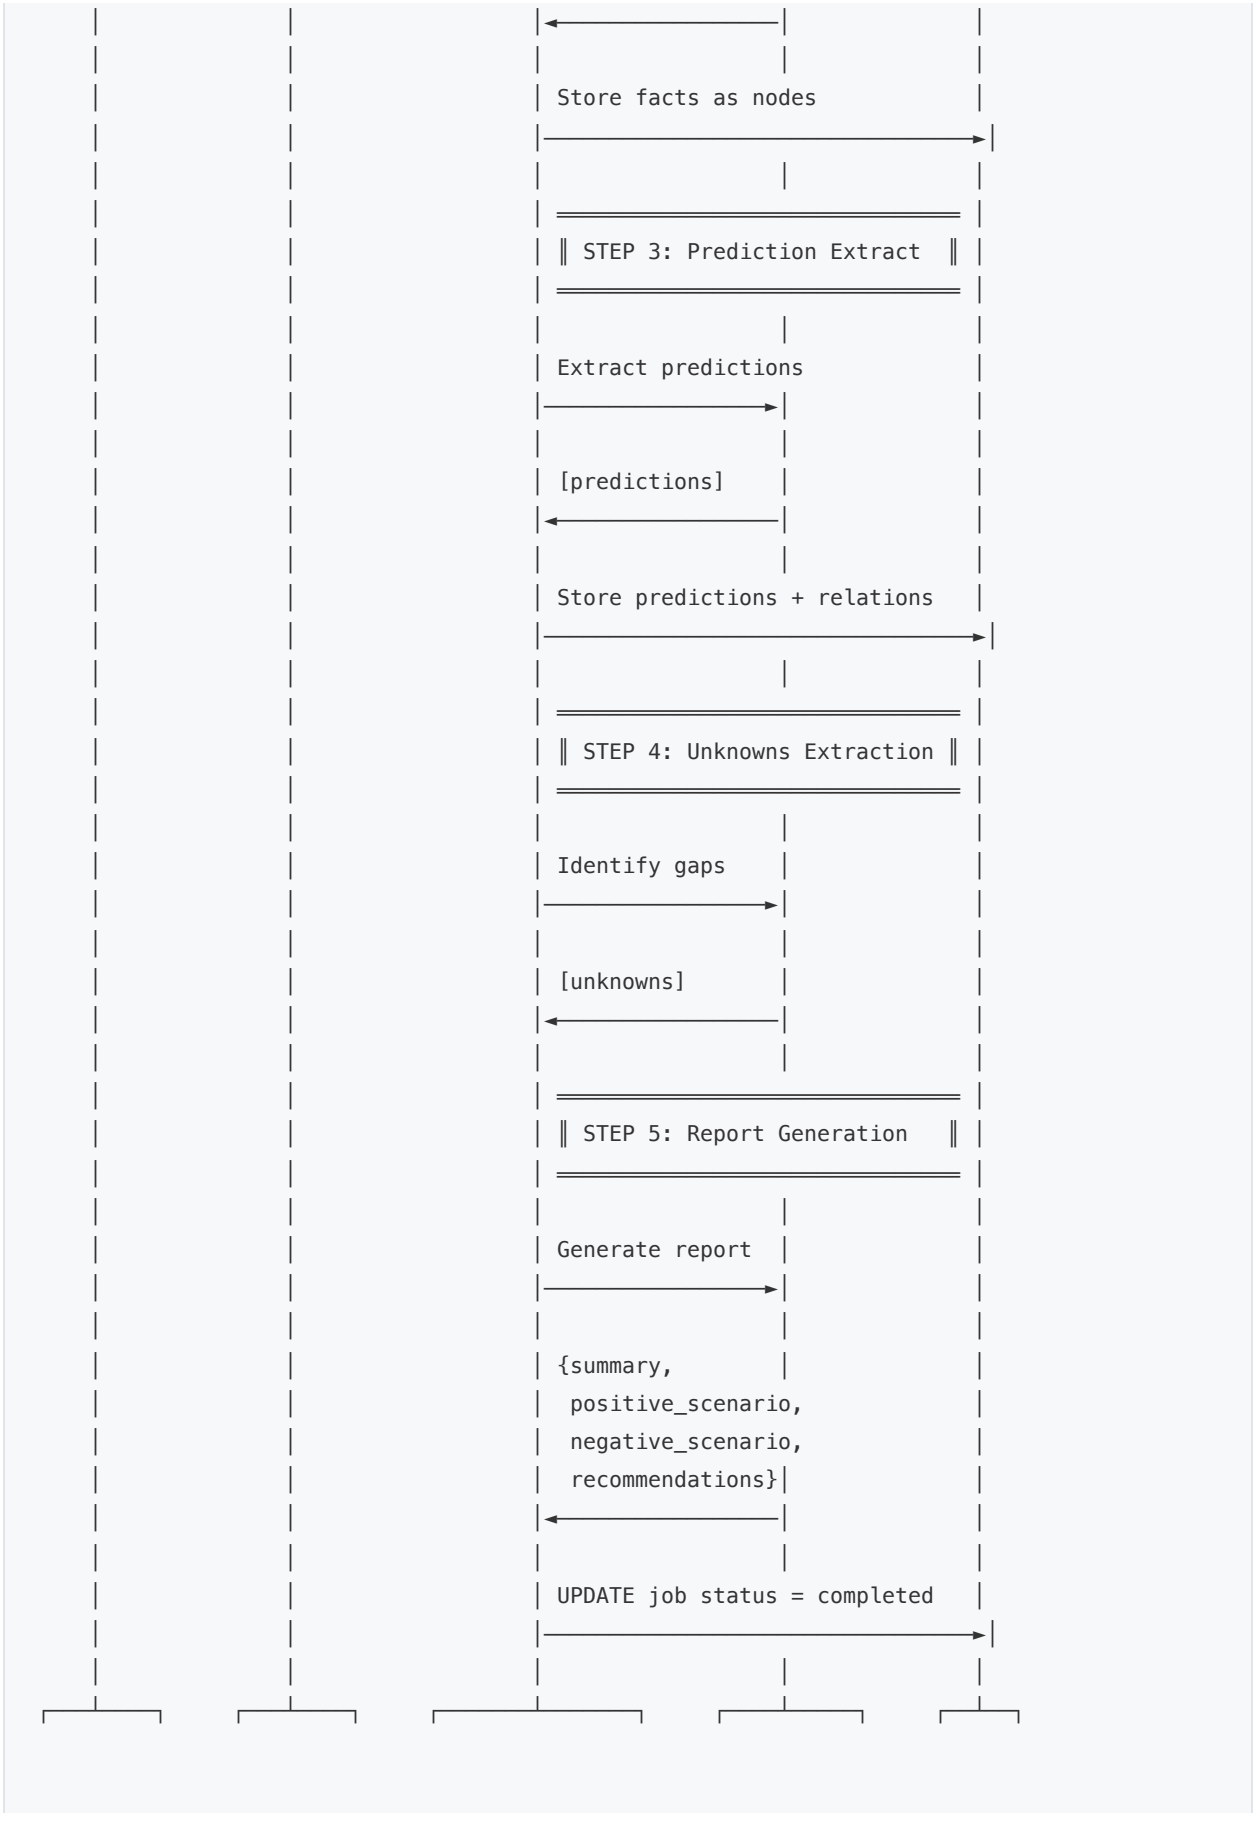
Store facts as nodes
STEP 3: Prediction Extract
Extract predictions
[predictions]
Store predictions + relations
STEP 4: Unknowns Extraction
Identify gaps
[unknowns]
STEP 5: Report Generation
Generate report
{summary,
positive_scenario,
negative_scenario,
recommendations}
UPDATE job status = completed

```
┌────────┐     ┌────────┐     ┌──────────────┐     ┌──────────┐     ┌──────┐
│ User   │     │Frontend│     │   Backend    │     │   LLM    │     │ DB   │
└────────┘     └────────┘     └──────────────┘     └──────────┘     └──────┘
```

---

4. Obsługiwane Formaty Danych

System akceptuje różnorodne formaty wejściowe:

4.1 Dokumenty

Format	Rozszerzenie	Biblioteka konwersji
PDF	`.pdf`	MarkItDown
Word	`.docx`	MarkItDown
PowerPoint	`.pptx`	MarkItDown
Excel	`.xlsx`	MarkItDown
Tekst	plain text	Native

4.2 Źródła Webowe

Typ	Obsługa	Technologia
Strony statyczne	✅	requests + BeautifulSoup
Strony dynamiczne (JS)	✅	**Playwright** – czeka na pełne załadowanie JS
SPA (Single Page Apps)	✅	Playwright z `wait_until='networkidle'`

Kluczowa funkcjonalność: System wykorzystuje Playwright do renderowania stron dynamicznych. Po nawigacji do URL czeka na zakończenie aktywności sieciowej (`networkidle`), co gwarantuje pobranie treści generowanych przez JavaScript.

---

5. Stos Technologiczny

5.1 Frontend

Technologia	Wersja	Rola
React	18.x	Framework UI
Vite	6.x	Build tool
React Router	6.x	Routing
Tailwind CSS	3.x	Stylowanie
Lucide React	-	Ikony
Nginx	latest	Production server

5.2 Backend

Technologia	Wersja	Rola
Python	3.11+	Runtime
Flask	3.0.0	Framework API
Gunicorn	22.0.0	WSGI Server (4 workers)
psycopg2	2.9.9	PostgreSQL driver
pgvector	0.2.4	Vector operations
Playwright	latest	Web scraping dynamiczny

Technologia	Wersja	Rola
MarkItDown	latest	Konwersja dokumentów
BeautifulSoup4	4.12.2	HTML parsing

5.3 Baza Danych

Technologia	Wersja	Rola
PostgreSQL	16	Główna baza danych
pgvector	extension	Wyszukiwanie wektorowe

5.4 LLM & AI

Provider	Model	Użycie
Cloudflare Workers AI	Llama 3.1 70B Instruct	Główny provider (hostowany)
Ollama	Qwen3:30b-a3b / Llama2	Alternatywny (self-hosted)
Sentence Transformers	MiniLM-L12-v2	Embeddingi multilingwalne

---

6. Model Danych

6.1 Diagram ERD

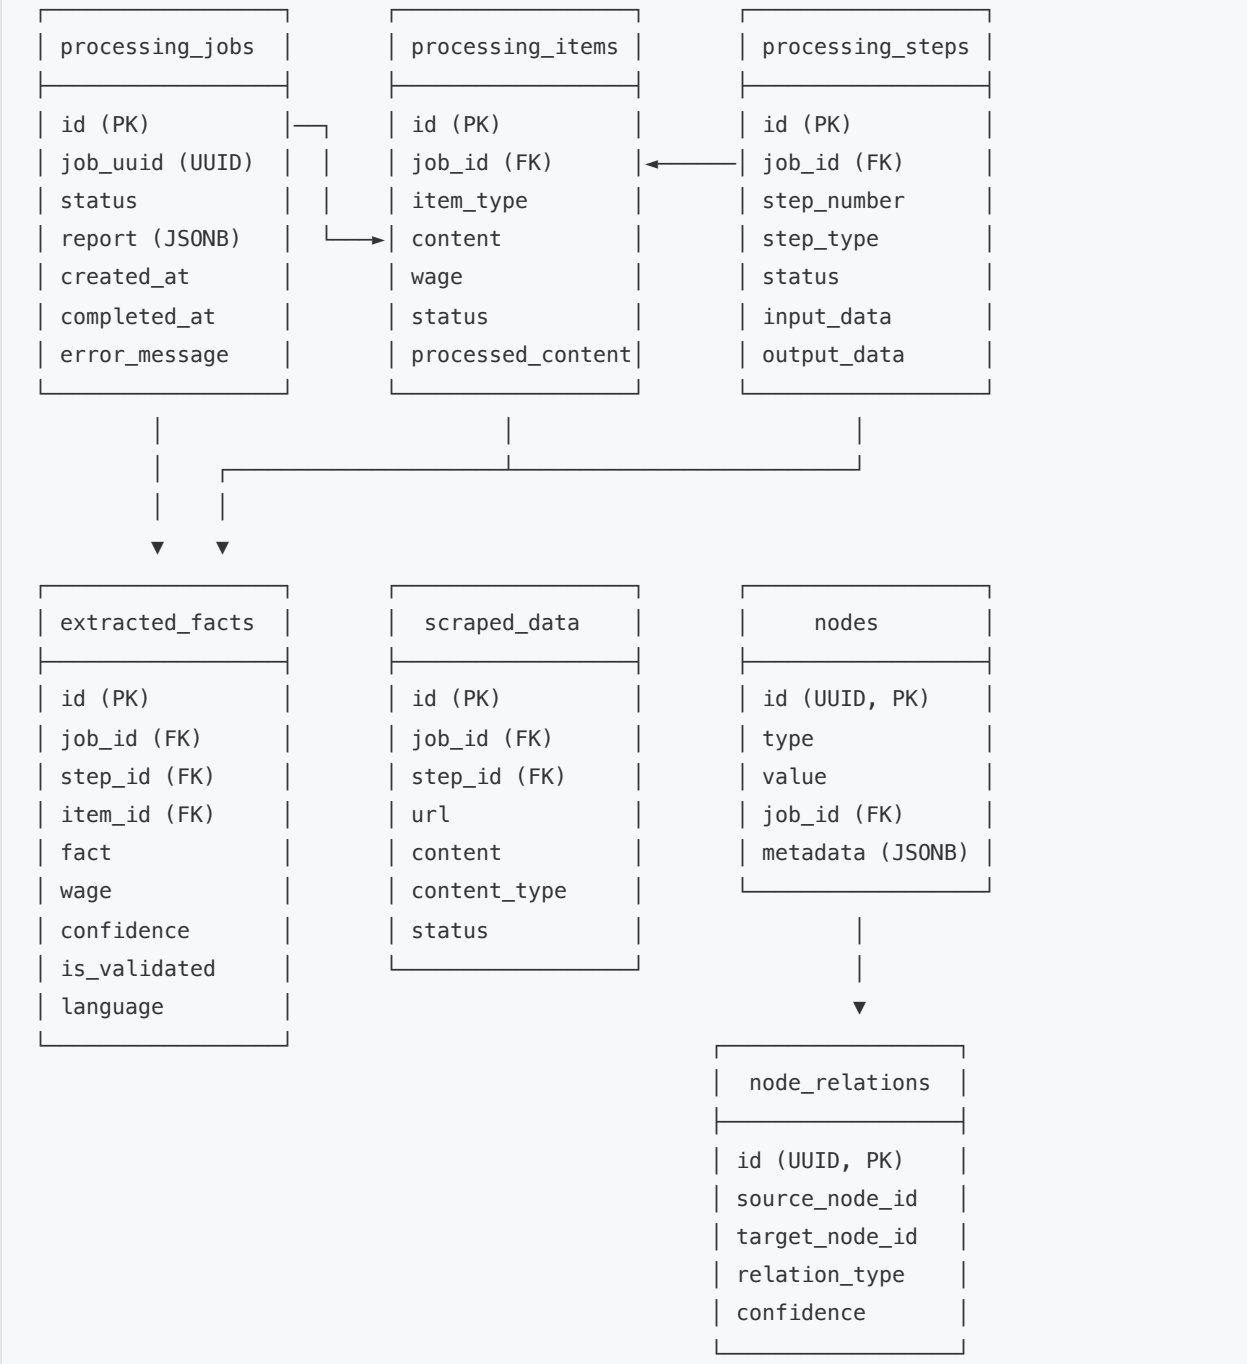

6.2 Typy Węzłów (Nodes)

Typ	Opis
`fact`	Wyekstrahowany fakt z dokumentu
`prediction`	Predykcja/prognoza wynikająca z faktów
`missing_information`	Zidentyfikowana luka informacyjna
`report`	Wygenerowany raport końcowy

6.3 Typy Relacji

Typ	Opis
`derived_from`	Węzeł wynika z innego węzła
`supports`	Węzeł wspiera/potwierdza inny węzeł
`contradicts`	Węzeł jest sprzeczny z innym węzłem
`requires`	Węzeł wymaga informacji z innego węzła
`suggests`	Węzeł sugeruje/implikuje inny węzeł

---

7. API Endpoints

7.1 Główne Endpointy

Metoda	Endpoint	Opis
`GET`	`/health`	Health check
`POST`	`/api/submit`	Utworzenie nowego zadania analizy
`GET`	`/api/jobs`	Lista wszystkich zadań
`GET`	`/api/jobs/{uuid}`	Szczegóły zadania z faktami, predykcjami i raportem
`GET`	`/api/jobs/{uuid}/nodes`	Węzły powiązane z zadaniem
`GET`	`/api/nodes/{id}`	Szczegóły pojedynczego węzła
`GET`	`/api/nodes/{id}/relations`	Relacje węzła

7.2 Przykład Request/Response

POST /api/submit

```
{
  "items": [
    {"type": "text", "content": "Treść do analizy", "wage": 100},
    {"type": "link", "content": "https://example.com/article", "wage": 80},
    {"type": "file", "content": "<base64>", "wage": 120}
  ],
  "processing": {
    "enable_scraping": true,
    "enable_fact_extraction": true,
    "language": "pl"
```

```
  }
}
```

Response:

```
{
  "job_uuid": "a1b2c3d4-e5f6-7890-abcd-ef1234567890"
}
```

---

8. Pipeline Przetwarzania

System wykonuje 5-etapowy pipeline przetwarzania:

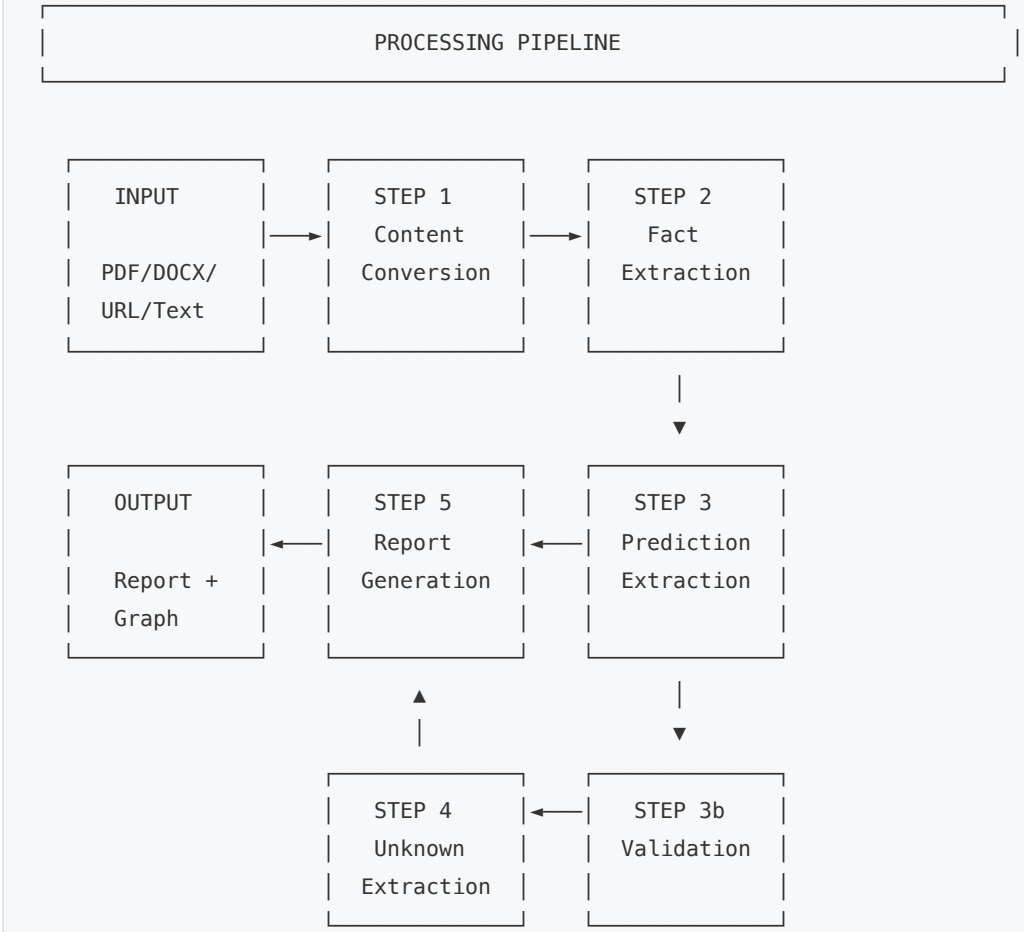

8.1 Szczegóły Kroków

Krok	Nazwa	Opis	LLM
1	Content Conversion	Konwersja PDF/DOCX/URL → Markdown	❌
2	Fact Extraction	Ekstrakcja kluczowych faktów	✅

Krok	Nazwa	Opis	LLM
3	Prediction Extraction	Generowanie predykcji na podstawie faktów	✅
4	Unknown Extraction	Identyfikacja brakujących informacji	✅
5	Report Generation	Tworzenie raportu JSON ze scenariuszami	✅

---

9. Struktura Raportu

System generuje raport w formacie JSON:

```
{
  "summary": "Streszczenie danych (max 150 słów) – przejrzyste, user-friendly",
  "positive_scenario": "Scenariusz pozytywny dla Atlantis z korelacjami (200–300 słów)",
  "negative_scenario": "Scenariusz negatywny dla Atlantis z korelacjami (200–300 słów)",
  "recommendations": "Rekomendacje decyzyjne do uniknięcia scenariuszy negatywnych"
}
```

---

10. Konfiguracja i Deployment

10.1 Zmienne Środowiskowe

```
# Database
DB_HOST=database
DB_PORT=5432
DB_NAME=hacknation
DB_USER=postgres
DB_PASSWORD=postgres

# LLM Provider: 'cloudflare' lub 'ollama'
LLM_PROVIDER=cloudflare

# Cloudflare Workers AI
CLOUDFLARE_ACCOUNT_ID=<your-account-id>
CLOUDFLARE_API_TOKEN=<your-api-token>
CLOUDFLARE_MODEL_EN=@cf/meta/llama-3.1-70b-instruct
CLOUDFLARE_MODEL_PL=@cf/meta/llama-3.1-70b-instruct

# Ollama (alternatywnie)
OLLAMA_HOST=host.docker.internal
OLLAMA_PORT=11434
OLLAMA_MODEL=qwen3:30b-a3b
```

10.2 Uruchomienie

```
# Produkcja (z Cloudflare AI)
docker-compose up -d

# Produkcja (CPU-only z Ollama)
docker-compose -f docker-compose.cpu.yml up -d

# Development
./start.sh
```

```
# Health check
./health-check.sh
```

10.3 Wymagania Sprzętowe

Komponent	Minimum	Zalecane
RAM	8 GB	16 GB
Dysk	20 GB	50 GB
CPU	4 cores	8 cores
GPU	Opcjonalnie	NVIDIA (dla Ollama)

---

11. Bezpieczeństwo

Aspekt	Status	Opis
CORS	✅	Skonfigurowane dla frontendu
Flask Debug	✅	Wyłączone w produkcji
Secrets	✅	Zmienne środowiskowe
Container Isolation	✅	Docker network isolation
Input Validation	✅	Walidacja requestów API

---

12. Analiza Kosztów LLM

12.1 Cloudflare Workers AI

Metryka	Wartość
Koszt 10k neuronów	~$0.11
Model	Llama 3.1 70B Instruct
Latency	~2-5s per request

12.2 Self-Hosted (Ollama)

Konfiguracja	Koszt miesięczny*
GPU Cloud (A100)	~$1000-2000
GPU Cloud (A10G)	~$300-600
On-premise (RTX 4090)	Jednorazowo ~$2000

*Szacunki dla intensywnego użycia

12.3 Rekomendacja

Dla małej skali (hackathon, MVP): **Cloudflare Workers AI** – brak upfront costs, pay-per-use.

Dla produkcji na większą skalę: **Self-hosted Ollama** – przewidywalny koszt, pełna kontrola.

---

13. Rozszerzalność

13.1 Łatwa Podmiana LLM

System obsługuje prostą podmianę providera LLM poprzez zmienną środowiskową `LLM_PROVIDER`: - `cloudflare` – Cloudflare Workers AI (domyślnie) - `ollama` – Lokalny/self-hosted Ollama

13.2 Dodawanie Nowych Formatów

Dzięki bibliotece MarkItDown dodanie obsługi nowych formatów wymaga minimalnych zmian w kodzie.

13.3 Graf Wiedzy

System wykorzystuje strukturę grafową (nodes + relations) umożliwiającą: - Wizualizację powiązań między faktami - Śledzenie pochodzenia predykcji - Identyfikację konfliktów informacyjnych

---

14. Podsumowanie

S.I.K.O.R.K.A. (System Inteligentnej Kompilacji Opinii, Raportów, Konfiguracji i Analiz) to w pełni funkcjonalny system analizy strategicznej wykorzystujący najnowsze osiągnięcia w dziedzinie LLM.

Kluczowe zalety:

#	Zaleta	Opis
1	**100% Open Source**	Brak zależności od zamkniętych rozwiązań
2	**Pełna konteneryzacja**	Gotowy do wdrożenia w dowolnej infrastrukturze Docker
3	**Elastyczny provider LLM**	Łatwa migracja między Cloudflare a self-hosted
4	**Niskie koszty**	~$0.11 za intensywną sesję testową
5	**Wieloformatowy input**	PDF, DOCX, PPTX, strony dynamiczne (JS)
6	**Kompleksowy output**	Fakty, predykcje, brakujące info, raport ze scenariuszami

---

Dokumentacja wygenerowana: Grudzień 2025 **S.I.K.O.R.K.A.** – Zespół "Wifi nie działa"